Sprawozdanie Etap 3 - MongoDB

Zaawansowane systemy baz danych

Krzysztof Dąbrowski (293101)
GR6 (Poniedziałek 8:15)

Spis treści

1 Wybrany zbór danych **1**

2 Instalacja MongoDB i wczytanie danych **2**
2.1 Instalacja MongoDB 2
2.2 Wczytanie danych 3
2.3 Podział na kolekcje 4
2.4 Relacje 4

3 Logika biznesowa **6**

4 Indeksy **7**

5 Transakcje **10**

Źródła **10**

Zastosowane skróty **12**

Spis rycin

1 Wczytanie pliku za pomocą MongoDB Compass 3
2 Utworzone kolekcje 4
3 Przykładowe zagniezdzenie i referencja 5

Spis tabel

1 Czas zapytania przed dodaniem indeksu 8
2 Czas zapytania po dodaniu indeksu 8

Spis wykazów

1 Top 3 słów kluczowych w dodatku Edge of Eternities 5
2 Top 3 najdroższych kart legalnych w standardzie 6
3 Utworzenie indeksu złożonego 9
4 Utworzenie indeksu typu Wildcard 9

Kod projektu

Kod projektu i sprawozdań jest dostępny na GitHub BoardBase

1 Wybrany zbór danych

W liceum zacząłem grać w grę karcianą Magic: The Gathering (MTG), która do dziś jest moim hobby. Gra MTG jest bardzo złożona, do tego stopnia, że za pomocą kart i mechanik *można zbudować maszynę Turinga* [1].
Gra zawiera bardzo wiele kart, z których każda ma zestaw parametrów zależnych od jej typu. Poza cechami kart związanymi bezpośrednio z rozgrywką, karty mają też dodatkowe cechy takie jak sety, w których zostały wydane, grafikę, która może różnić się między wydaniami, czy też przynależność do talii lub legalność w danych formatach gry. Istotnym cechą kart są też ich ceny, których zmienność prowadzi nawet do spekulacji cenowych i inwestycji niektórych graczy.

Z uwagi na moje zainteresowanie MTG, oraz złożoność danych o kartach i relacji między nimi zdecydowałem się użyć zbioru na ten temat. W tym celu skorzystałem z projektu MTGJSON [2], który jest otwarto źródłowym projektem katalogującym wiele informacji o MTG w przenośnych formatach jak na przykład JavaScript Object Notation (JSON).

W ramach projektu dostępne są tysiące zbiorów danych, ponieważ dla każdej oficjalnej talii czy set'u dostępne są dedykowane zbiory. Postanowiłem się skupić na formacie standard [3] i jednym wybranym secie i talii. Wybrałem więc zbiory:

- AllPricesToday - aktualne ceny każdego wydania dla każdej karty
- DeckList - metadane każdej oficjalnej talii
- SetList - metadane każdego dodatku
- Keywords - słowa kluczowe z kart
- CardTypes - typy kart

- Standard - podzbiór wszystkich kart legalnych w formacie standard [3]
- StandardAtomic - podstawowe informacje o kartach legalnych w formacie standard (bez rozróżnienia na różne wydania tej samej karty)
- set Edge of Eternities (endpoint do pobrania informacji o wybranym dodatku)
- deck World Shaper - (endpoint do pobrania informacji o wybranej talii)

Dane zawierają złożone struktury, wiele pól i referencje na dane z innych zbiorów.

2 Instalacja MongoDB i wczytanie danych

Przygotowanie bazy MongoDB [4].

2.1 Instalacja MongoDB

Wybrałem wersję MongoDB Community, ponieważ chciałem skonfigurować lokalną wersję bazy i nie płacić za licencję wersji Enterprise. Rozważałem też użycie MongoDB Atlas [5], ale uznałem, że wolę lokalnie działającą wersję.

Ponieważ w poprzednich etapach dobrze sprawdzała mi się instalacja jako obraz Docker tym razem też się na to zdecydowałem. Skonfigurowałem uruchomienie obrazu w pliku `docker-compose.yml`, kierując się oficjalnym poradnikiem Install MongoDB Community Edition [6].
Niestety oficjalna strona obrazu wersji community [7] nie opisuje jakie są możliwe tagi, ani jak rozumieć zastosowane w nich skróty. Na szczęście strona do wersji open source obrazu MongoDB [8] jest lepiej opisana.
Nie byłem pewien, który obraz wybrać, ale sugerując się wątkiem na reddit [9] pozostałem przy obrazie `mongodb/mongodb-community-server`.
Dowiedziałem się, że jest on dostępny w wersji bazującej na Redhat i Ubuntu. Wybrałem wersję na Ubuntu, ponieważ mam większe doświadczenie z tą dystrybucją, choć pewnie nie będzie to miało znaczenia.

Po uruchomieniu kontenera połączyłem się do niego `mongosh` i pobrałem informacje o bazie poleceniem `db.runCommand({hello:1})` jak w samouczku [6].
Zobaczyłem JSON z informacjami o bazie, co potwierdza, że działą ona poprawnie.

Skonfigurowałem login i hasło użytkownika `root`, żeby ograniczyć dostęp do bazy.
Rozważałem też ustawienie innych opcji [10], ale uznałem, że na tym etapie domyślne ustawienia mi pasują.

2.2 Wczytanie danych

Na początku spróbowałem wczytać dane za pomocą MongoDB Compass (Compass) [11]. Zorientowałem się jednak, że ponieważ moje dane są pojedynczymi plikami JSON to do kolekcji został dodany tylko jeden dokument zawierający wszystkie dane (Rysunek 1).

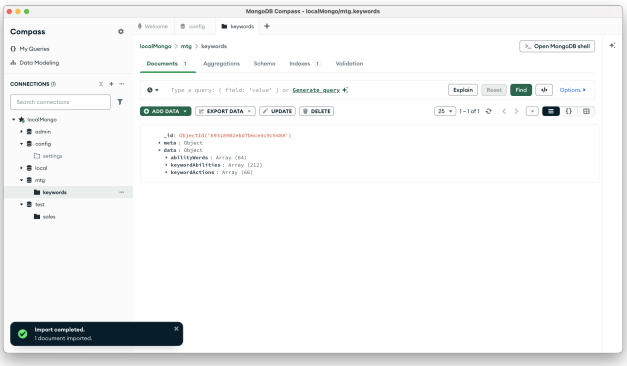

Rysunek 1: Wczytanie pliku za pomocą MongoDB Compass

W dokumentacji przeczytałem, że dobrym sposobem na wczytanie danych z JSON jest użycie narzędzia `mongoimport` razem z `jq` do transformacji danych [12]. Skrypty wczytujące dane umieściłem w katalogu `mongo/importData/`.

Na początku miałem problem z uwierzytelnieniem. Udało mi się go rozwiązać kodując hasło w connection string używając URL encoding, zgodnie z przykładem z poradnika Decoding Encoded URLs in Linux [13].

Po wczytaniu danych zauważyłem, że wszystkie pola mają typ `string`. Przeczytałem, że w przypadku importu z JSON wszystkie pola są zapisywane jako `string` [14]. Przygotowałem więc skrypty `.mongodb.js` w `mongo/importData/`, które dostosowują typy we wczytanych dokumentach.

2.3 Podział na kolekcje

Ponieważ projekt MTGJSON [2] już rozsądnie grupuje różne rodzaje danych, to w mojej bazie załadowałem każdy ze zbiorów danych do osobnej kolekcji. W przypadku niektórych zbiorów podzieliłem dane na mniejsze dokumenty. Zrobiłem tak na przykład w `importKeywords.sh`.
Gdybym używał danych wielu tali lub setów umieściłbym je wszystkie w kolekcjach `decks` i `sets`. Jednak, ponieważ mam już wiele zestawów danych, to wybrałem tylko po jednej tali i secie. Utworzone kolekcje są widoczne na Rysunek 2.

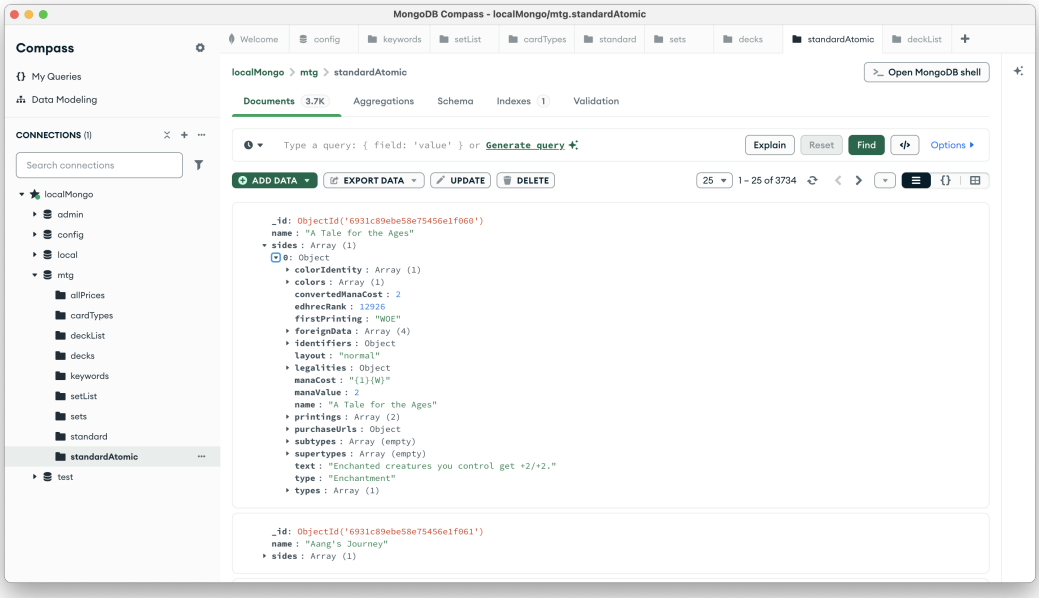

Rysunek 2: Utworzone kolekcje

2.4 Relacje

Wybrane przeze mnie zbiory posiadają już za równo zagniezdzone dokumenty jak i referencje (Rysunek 3). Nie musiałem więc modyfikować ich struktury, poza zmianami, na które zdecydowałem się przy wczytywaniu danych (Sekcja 2.2).

Różnica między zagnieżdżeniem a referencją polega na tym, że w przypadku zagniezdzenia całe dane są przechowywane w bazowym dokumencie, a referencja przechowuje tylko identyfikator danych w innym dokumencie.
Referencja przypomina bardziej znormalizowany model relacyjny. Stosując MongoDB zalecane jest jednak zagniezdzanie danych, gdy są one często czytane razem, ponieważ znacznie przyśpiesza to regularne działanie bazy [15].

Byłem ciekaw jakie są najczęstsze słowa kluczowe w kartach z dodatku *Edge of Eternities*. W tym celu napisałem zapytanie w pliku `usingNestedData.mongodb.js`, które to wylicza.
Wynik zapytania z filtrem na 3 najczęstsze słowa kluczowe widać w Wykaz 1.

Do pokazania relacji napisałem zapytanie `mostExpensiveStandardCards.mongodb.js` wyświetlające najdroższe karty legalne w standardzie. Kolekcja `standard` zawiera informacje o kartach, ale ich aktualne ceny są w kolekcji `allPrices`. Kolekcja `allPrices` zawiera jedynie id kart i dane o cenach.

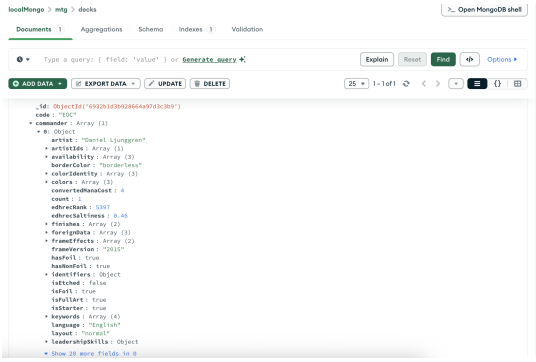

(a) Przykład zagniezdzonych danych

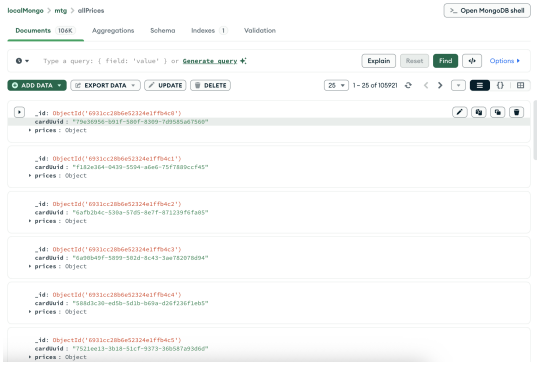

(b) Przykład referencji

Rysunek 3: Przykładowe zagniezdzenie i referencja

Zapytanie działało bardzo wolno dla 6440 kart. Prawdopodobnie dodanie indeksów przyśpieszyłoby działanie, ponieważ indeksy są tematem innego etapu, to na razie ograniczyłem liczbę przetwarzanych kart do 100.
Wyniki zapytania dla 3 najdroższych kart przedstawiam w Wykaz 2.

3 Logika biznesowa

Do implementacji logiki biznesowej zdecydowałem się użyć zewnętrznych funkcji w MongoDB Playgrounds [16].
Rozważałem użycie `$function` [17], jednak uznałem, że oferują zbyt małe możliwości do solidnej implementacji logiki biznesowej. Dodatkowo użycie `$function` nie jest rekomendowane [17].

Napisany kod umieściłem w katalogu `mongo/businessLogic/`.

- `addKeyword.mongodb.js` - dodaje słowo kluczowe do odpowiedniego dokumentu. Sprawdzana jest poprawność typu słowa kluczowego, a następnie jest ono dodawane do odpowiedniej listy, jeśli jeszcze go tam nie ma.
- `addCardmarketPrice.mongodb.js` - dodanie ceny danej karty jako cena z Cardmarket. Funkcja znajduje `uuid` karty na podstawie jej nazwy i dodaje podaną cenę z aktualną datą.
- `addDeckList.mongodb.js` - dodanie informacji o talii. Funkcja waliduje typ talii oraz automatyczne generuje `fileName` na podstawie nazwy i kodu talii.

Na początku implementując `addCardmarketPrice` nadpisywałem cały dokument w `$set`. Traciłem przez to ceni z poprzednich dni. Na forum [18] znalazłem rozwiązanie, że należy użyć *Dot Notation* [19], żeby zaktualizować tylko wybrane pola.

Wykaz 1 Top 3 słów kluczowych w dodatku Edge of Eternities

```
[
  {
    "_id": "Flying",
    "count": 59
  },
  {
    "_id": "Warp",
    "count": 52
  },
  {
    "_id": "Station",
    "count": 47
  }
]
```

Uznałem, że w moim przypadku **sekwencje do autoinkrementacji** nie są potrzebne. Szczególnie w środowiskach rozproszonych używanie tego typu sekwencji może sprawiać problemy z synchronizacją wartości. Na przykład w sytuacji równoległego dodania dwóch dokumentów. Gdybym w przyszłości potrzebował sekwencji, to zaimplementowałbym je bazując na artykule *MongoDB Auto-Increment* [20].

Agregację danych wykonałem w zapytaniach testujących relacje. Przygotowałem też nowe zapytanie wyliczające podstawowe statystyki dla danej talii w pliku `deckStatistics.mongodb.js`.

- `usingNestedData.mongodb.js` - wyszukanie najczęstszych słów kluczowych
- `mostExpensiveStandardCards.mongodb.js` - wyszukanie najdroższych kart legalnych w standardzie
- `deckStatistics.mongodb.js` - wyliczenie podstawowych statystyk talii

Analogiczne elementy, które warto dodać w pełnej wersji aplikacji:

- funkcje do dodawania cen dla innych sklepów i cen wersji online
- funkcję do dodawania i aktualizacji typów kart
- funkcję do dodawania nowych kart lub aktualizacji istniejących
- funkcję do dodawania i aktualizacji setów
- funkcję do dodawania i aktualizacji szczegółowych informacji o taliach
- analiza trendów cen danych kart
- wyliczenie wartości kolekcji podanych kart
- rozbudowanie wyliczania statystyk dla danej talii o więcej parametrów

Wykaz 2 Top 3 najdroższych kart legalnych w standardzie


```
[
  {
    "cardUuid": "73030017-9483-5f73-b4be-0660e1a5c1eb",
    "cardName": "Simulacrum Synthesizer",
    "rarity": "mythic",
    "type": "Artifact",
    "setCode": "BIG",
    "cardMarketPrice": "80.48 EUR"
  },
  {
    "cardUuid": "1ff3d49d-979d-5237-b2dd-28f4da08401a",
    "cardName": "Vaultborn Tyrant",
    "rarity": "mythic",
    "type": "Creature - Dinosaur",
    "setCode": "BIG",
    "cardMarketPrice": "61.62 EUR"
  },
  {
    "cardUuid": "c3cfc938-9b15-5ca1-9361-e89523d310dd",
    "cardName": "Simulacrum Synthesizer",
    "rarity": "mythic",
    "type": "Artifact",
    "setCode": "BIG",
    "cardMarketPrice": "47.21 EUR"
  }
]
```


4 Indeksy

Używając zapytania wyszukującego najdroższe karty, zauważyłem, że było ono bardzo wolne. Przypuszczam, że wynika to z operacji `$lookup`. Żeby to zweryfikować użyłem metody `explain`. Pozwala ona przeanalizować dane o wykonaniu zapytania, takie jak czas poszczególnych etapów [21].
Za pomocą `explain("executionStats")` zbadałem czas wykonania poszczególnych etapów zapytania (Tabela 1).

Tabela 1: Czas zapytania przed dodaniem indeksu

Etap	Czas wykonania etapu (ms)	Całkowity czas (ms)
$unwind	10	10

Etap	Czas wykonania etapu (ms)	Całkowity czas (ms)
$limit	0	10
$project	0	10
$lookup	7047	7057
$addFields	0	7057
$sort	0	7057
$project	0	7057

Widać, że największy narzut pochodzi z etapu `$lookup` (Tabela 1). Ponieważ `$lookup` wyszukuje dokumenty w kolekcji `allPrices` po polu `uuid`, to dodanie indeksu powinno to przyśpieszyć.

Dodałem indeks na polu `cardUuid` w kolekcji `allPrices` za pomocą skryptu `createIndexes.mongodb.js`.

Tabela 2: Czas zapytania po dodaniu indeksu

Etap	Czas wykonania etapu (ms)	Całkowity czas (ms)
$unwind	5	5
$limit	0	5
$project	0	5
$lookup	27	32
$addFields	0	32
$sort	0	32
$project	0	32

Po ponownym przeanalizowaniu zapytania widać, że czas etapu `$lookup` zmniejszył się z 7047 ms do 27 ms (Tabela 2). Jest to bardzo znacząca poprawa wydajności.
Podobnie jak w przypadku kluczy obcych w bazach relacyjnych, indeksy są kluczowe dla zaczytywania danych z innych kolekcji.

Żeby uniknąć wpływu cache na testy wydajności usuwałem kontener z bazą i tworzyłem go ponownie pomiędzy testami.

Zachęcony poprawą wydajności usunąłem ograniczenie brania tylko 100 pierwszych kart i przeanalizowałem ceny wszystkich 6440 kart ze standardu. Zapytanie, które wcześniej wykonywało się tak długo, że nie chciałem na nie czekać, teraz wykonało się poniżej 1 sekundy!

Gracze często szukają kart po ich nazwach. Żeby to przyśpieszyć dodałem indeksy na nazwach kart. W kolekcji `standardAtomic` dodałem zwykły indeks *Single Field* [22] na polu `name`, a w kolekcji `standard` na polu `cards.name` indeks *Multikey* [23]. Dodałem podobne indeksy do wyszukiwania innych elementów po ich nazwach lub kodach.

Tego typu indeksy testowałem analizując statystyki wykonania z włączonym i wyłączonym indeksem w pliku `cardSearchByName.mongodb.js`.

Gracze często szukają kart do swoich talii bazując na kolorze karty i jej koszcie many. Żeby przyśpieszyć tego typu wyszukiwania utworzyłem *Compound Index* [24]. Ponieważ tylko przednia strona karty jest istotna przy tego typu wyborze, ustawiłem indeks na pierwszym elemencie listy stron kart (Wykaz 3).
Indeksy na tego typu zagniezdzonych wartościach nie są możliwe do utworzenia w relacyjnych bazach danych, gdzie indeksuje się całe kolumny.

Wykaz 3 Utworzenie indeksu złożonego

```
db.standardAtomic.createIndex({ "sides.0.colors": 1 }, {
↪  "sides.0.manaValue": 1 });
```

W indeksach złożonych kolejność pól ma istotne znaczenie. Kierowałem się zasadą ESR [25], najpierw wybierając kolor, po którym użytkownicy będą zazwyczaj bezpośrednio filtrować, a potem dając koszt many, który będzie częściej wyszukiwany w zakresach.
W ten sposób dane o wartościach many w ramach danego koloru są **ułożone obok siebie w indeksie**, zapytania tego typu są wydajne.
Testując zapytania tego typu w pliku `cardForDeckSlot.mongodb.js` ustaliłem, że indeks znacząco przyśpiesza wyszukiwanie.

Ponieważ z czasem w MTG pojawiają się nowe formaty, na obiekcie opisującym legalność karty ustawiłem indeks *Wildcard* [26] poleceniem z Wykaz 4.
Dzięki temu rodzajowi indeksu nie muszę jawnie podawać pól, które będą indeksowane. Indeks obejmie wszystkie pola zagnieżdżone pod `sides.legalities`, nawet gdy z czasem dojdzie nowy rodzaj formatu.
Indeksy tego rodzaju raczej nie występują w bazach relacyjnych.

Wykaz 4 Utworzenie indeksu typu Wildcard

```
db.standardAtomic.createIndex({ "sides.legalities.$**": 1 });
```

Pozostałe indeksy, które założyłem są w pliku `createIndexes.mongodb.js`.

5 Transakcje

Źródła

1. Churchill A, Biderman S, Herrick A (2019) Magic: The Gathering is Turing Complete

2. MTGJSON - Portable formats for all Magic: The Gathering data. https://mtgjson.com/. Accessed 29 lis 2025

3. MTG Standard Format | Magic: The Gathering. https://magic.wizards.com/en/formats/standard. Accessed 29 lis 2025

4. MongoDB: The World's Leading Modern Database | MongoDB. https://www.mongodb.com/. Accessed 29 lis 2025

5. Atlas Database | MongoDB. https://www.mongodb.com/products/platform/atlas-database. Accessed 29 lis 2025

6. Install MongoDB Community Edition - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/administration/install-community/?operating-system=docker&search-docker=with-search-docker#install-mongodb-community-edition. Accessed 29 lis 2025

7. mongodb/mongodb-community-server - Docker Image. https://hub.docker.com/r/mongodb/mongodb-community-server. Accessed 29 lis 2025

8. mongo - Official Image | Docker Hub. https://hub.docker.com/_/mongo. Accessed 29 lis 2025

9. (2023) Difference between mongo and mongodb/community-server : r/mongodb. https://www.reddit.com/r/mongodb/comments/1658qs8/difference_between_mongo_and/. Accessed 29 lis 2025

10. Self-Managed Configuration File Options - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/reference/configuration-options/#mongodb-setting-auditLog.auditEncryptionKeyIdentifier. Accessed 4 grudz 2025

11. MongoDB Compass | MongoDB. https://www.mongodb.com/products/tools/compass. Accessed 4 grudz 2025

12. mongoimport Example Guide - Database Tools - MongoDB Docs. https://www.mongodb.com/docs/database-tools/mongoimport/mongoimport-guide/#useful-command-line-tools. Accessed 4 grudz 2025

13. Ballard M (2022) Decoding Encoded URLs in Linux | Baeldung on Linux. https://www.baeldung.com/linux/decoding-encoded-urls. Accessed 4 grudz 2025

14. Importing data via mongoimport and dates - Working with Data / Developer Tools - MongoDB Community Hub. https://www.mongodb.com/community/forums/t/importing-data-via-mongoimport-and-dates/117242/6. Accessed 5 grudz 2025

15. Best Practices for Data Modeling in MongoDB - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/data-modeling/best-practices/#std-label-embedding-vs-references. Accessed 5 grudz 2025

16. Explore Your Data with Playgrounds - VS Code Extension - MongoDB Docs. https://www.mongodb.com/docs/mongodb-vscode/playgrounds/. Accessed 5 grudz 2025

17. $function (expression operator) - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/reference/operator/aggregation/function/#mongodb-expression-exp.-function. Accessed 5 grudz 2025

18. (2024) How to update a collection item without removing non existing values send on the query? - Working with Data / Node.js Frameworks - MongoDB Community Hub. https://www.mongodb.com/community/forums/t/how-to-update-a-collection-item-without-removing-non-existing-values-send-on-the-query/267405. Accessed 5 grudz 2025

19. Documents - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/core/document/#std-label-document-dot-notation. Accessed 5 grudz 2025

20. MongoDB Auto-Increment | MongoDB. https://www.mongodb.com/resources/products/platform/mongodb-auto-increment. Accessed 5 grudz 2025

21. Analyze Query Performance - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/tutorial/evaluate-operation-performance/. Accessed 6 grudz 2025

22. Single Field Indexes - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/core/indexes/index-types/index-single/. Accessed 6 grudz 2025

23. Multikey Indexes - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/core/indexes/index-types/index-multikey/. Accessed 6 grudz 2025

24. Compound Indexes - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/core/indexes/index-types/index-compound/. Accessed 6 grudz 2025

25. The ESR (Equality, Sort, Range) Guideline - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/tutorial/equality-sort-range-guideline/#std-label-esr-indexing-guideline. Accessed 6 grudz 2025

26. Wildcard Indexes - Database Manual - MongoDB Docs. https://www.mongodb.com/docs/manual/core/indexes/index-types/index-wildcard/. Accessed 6 grudz 2025

Zastosowane skróty

Compass MongoDB Compass
JSON JavaScript Object Notation
MTG Magic: The Gathering